

Deteção de Deepfakes: Uma Abordagem com SigLIP2 e Explicabilidade via Grad-CAM

Jessica Fileto¹

¹ Centro de Matemática, Computação e Cognição
Universidade Federal do ABC (UFABC)
Av. dos Estados, 5001 – 09210-580 – Santo André – SP – Brasil

jessica.fileto@ufabc.edu.br

Resumo. Um dos grandes desafios atuais é a mitigação da desinformação, especialmente com o advento de vídeos sintéticos hiper-realistas, conhecidos como deepfakes. O desenvolvimento de técnicas de detecção de deepfakes é crucial para preservar a integridade da informação e proteger indivíduos contra a disseminação de conteúdo falso. Além disso, a explicabilidade dos modelos de detecção é essencial para aumentar a confiança dos usuários e permitir uma compreensão mais profunda das decisões do modelo. Este artigo propõe uma abordagem para a detecção de deepfakes utilizando SigLIP2 para extração de características visuais, juntamente com técnicas de explicabilidade, como Grad-CAM, para fornecer insights sobre as decisões do modelo. A metodologia envolve o pré-processamento de dados, extração de características com SigLIP2, seguida pela classificação utilizando redes neurais profundas. A avaliação do desempenho do modelo é realizada através de métricas de precisão. Para garantir a robustez do modelo, é realizado o teste da generalização em diferentes datasets, sendo estes: Celeb-DF e um dataset customizado.

Abstract. One of the major challenges today is the mitigation of disinformation, particularly with the advent of hyper-realistic synthetic videos known as deepfakes. The development of deepfake detection techniques is crucial for preserving information integrity and protecting individuals against the dissemination of false content. Furthermore, the explainability of detection models is essential for increasing user trust and enabling a deeper understanding of model decisions. This paper proposes an approach for deepfake detection using SigLIP2 for visual feature extraction, together with explainability techniques such as Grad-CAM to provide insights into the model's decisions. The methodology involves data preprocessing, feature extraction with SigLIP2, followed by classification using deep neural networks. Model performance is evaluated through precision metrics. To ensure model robustness, generalization testing is conducted across different datasets, namely: Celeb-DF and a custom-built dataset.

1. Introdução

A divulgação de conteúdo é uma das formas mais comuns de comunicação, principalmente com o advento das redes sociais. Mídias diversas podem ser distribuídas como foto, áudio e vídeo.

Com o acesso facilitado a ferramentas de inteligência artificial generativa (GenAI), como por exemplo, Kling AI [Kling 2026], Runway [Runway 2026] e o próprio Veo da

Google [Google 2026], os usuários conseguem através de imagens (IPV) e texto (TPV) gerar vídeos hiper realistas, o que torna imperceptível ao ser humano detectar se foi gerado sinteticamente ou não. Estes vídeos podem ser utilizados para espalhar desinformação e causar danos a sociedade como um todo. Um dos métodos mais comuns de desinformação é o *deepfake*, que consiste em vídeos ou imagens manipuladas com o intuito de enganar o público. Os *deepfakes* são criados utilizando *deep learning*, que é uma técnica de aprendizado de máquina, para substituir o rosto de uma pessoa por outro em um vídeo existente, ou criar um vídeo completamente novo com a aparência de uma pessoa real. [Dagar e Vishwakarma 2022]

Apesar de passar credibilidade, as pessoas tendem a não acreditar na mensagem passada, caso o conteúdo não seja condizente. Por exemplo, um político moderado ter falas de extrema direita, porém caso a alteração seja sutil existe uma tendência a não ser percebido como *deepfake*. [Hameleers, van der Meer e Dobber 2022]; [Hameleers, Meer e Dobber 2024]

Segundo Hameleers, van der Meer e Dobber (2022, p. 10) “A desinformação que é congruente com as crenças anteriores das pessoas pode reforçar as crenças existentes.”

A quantidade massiva de conteúdo sintético nas redes sociais ocasiona a fadiga de discernimento da autenticidade do conteúdo que o usuário interage e impacta sua capacidade e vontade de interagir criticamente com os meios de comunicação, que propicia a aceitação passiva do conteúdo disponível. [Liu, Wang e Luo 2025]

Segundo o relatório da *Security Hero*, 98% das *deepfakes* online são de pornografia. [Security 2023] Em relação ao Brasil, o relatório da Agência Lupa aborda o crescimento de 25,77% no uso de GenIA na disseminação de desinformação no ano de 2025, sendo o tipo de conteúdo mais disseminado, o vídeo. O maior alvo de desinformação continua sendo a polarização política, atingindo 50,2% da quantidade de conteúdos nacionais analisados pela Agência Lupa em 2025. [Corrêa 2026] A *SaferNet* fez um levantamento dos casos de *deepfakes*, focados em *deepfakes* de pornografia em escolas brasileiras. Neste âmbito dos 27 estados foram constatados 10 estados com relatos desta prática. [SaferNet 2026]

Os danos desta prática são imensos, visto que mesmo que ocorra a detecção do conteúdo *fake*, no caso o *deepfake* de pornografia, isto não impede sua rápida disseminação e reenvio entre plataformas. Por fim, saber que uma imagem é falsa não anula os danos ou perda de dignidade infligida à pessoa retratada. [Mahr 2026]

2. Trabalhos relacionados

Com o aumento da criação de *deepfakes*, houve também uma crescente pesquisa relacionada aos métodos de detecção. Inicialmente, principalmente no campo forense, eram utilizadas técnicas voltadas a análise *pixel a pixel*. O objetivo é encontrar inconsistências *frame a frame*, relacionados ao piscar dos olhos, postura, diferenças de tom de pele e inconsistências da iluminação. [Dagar e Vishwakarma 2022]

As técnicas tradicionais de aprendizado de máquina (ML), também são empregadas na detecção de *deepfakes*, sendo as mais comumente utilizadas o *perceptron* multicamada (MLP), regressão logística (LR) dentre outros modelos que são o estado da arte. [V. K. Sharma, Garg e Caudron 2025]

Com o avanço das técnicas de geração de *deepfakes*, foi necessário também avançar

nos métodos de detecção. Os métodos mais utilizados atualmente são os modelos baseados em *Deep Learning*, como por exemplo, redes neurais convolucionais (CNN), redes neurais recorrentes (RNN) e redes neurais convolucionais baseadas em região (RCNN). [V. K. Sharma, Garg e Caudron 2025]; [Rana et al. 2022]

Conforme T, Pandeewaran e Morin (2025) “Após o sucesso dos transformadores em visão computacional (ViT), houve uma exploração do ViT e variantes espaço-temporais [...]”. Um desses modelos utilizados é o *SigLIP*, que por ser pré-treinado em um extenso *dataset* é costumeiramente utilizado como um *backbone* congelado para extração de características.

3. Delimitação e Escopo

Os *datasets* utilizados neste trabalho são os seguintes:

1. FaceForensics++ para o treinamento do modelo [Rössler et al. 2019]
2. CelebDF para a validação cruzada [Li et al. 2020]
3. *Dataset* customizado com vídeos de redes sociais como *Instagram* e *TikTok*, além de vídeos do *Youtube*

Nas próximas seções se estabelecerá a execução do trabalho. Na seção 4, se discutirá a metodologia, construção do modelo de detecção a ser implementado. Logo, os resultados e discussões serão apresentados na seção 5. Finalmente, as conclusões sobre o trabalho serão expostos na seção 6.

4. Metodologia

A metodologia adotada neste trabalho segue o estado da arte na detecção de deepfake.

Primeiramente será realizada a extração dos rostos dos *frames* dos vídeos, para tal, será utilizada a biblioteca MTCNN para detecção e recorte dos rostos. [K. Zhang et al. 2016]; [Kaipeng Zhang et al. 2017]

Com a extração de rostos concluída, ocorrerá a extração de características utilizando o *backbone* congelado *SigLip2*. O modelo escolhido foi o *siglip2_base_patch16_224* que contém 375.19 milhões de parâmetros. [Tschannen et al. 2025]

Para otimizar o tempo de processamento, a etapa de extração de rostos foi realizada localmente.

O treinamento do modelo, que inclui o passo de extração das features foi realizado na nuvem, através do plano gratuito do *Google Colab*. As características extraídas são salvas, criando um *cache*, para caso seja necessário um *fine tuning* no classificador não ocorra a extração das características novamente, o que agiliza o processo de experimentação.

Para a avaliação do desempenho do modelo, serão analisadas as seguintes métricas: acurácia, precisão, área sob a curva *ROC* (*AUC*) e *recall*. [V. K. Sharma, Garg e Caudron 2025]

Com o objetivo de viabilizar a explicabilidade às decisões tomadas pelo modelo, após a inferência, foi inserida a biblioteca *GRAD-CAM*. [Selvaraju et al. 2016] Como o modelo construído é baseado em *transformers*, por conta da utilização do *SigLip2*, foi necessária a adaptação da biblioteca para o uso neste contexto.

4.1. Divisão dos dados

4.1.1. Treinamento

Os dados foram divididos com o método *GroupShuffleSplit* da biblioteca *scikit-learn*, nas proporções de 70%, 15% e 15% para treinamento, validação e teste, respectivamente.

4.1.2. Validação cruzada

A validação cruzada foi realizada tanto *in-domain* quanto *cross-domain*, para garantir a robustez do modelo.

A validação *in-domain* foi realizada nos 15% definidos como conjunto de teste. Já a validação *cross-domain* foi realizada em 400 vídeos do *Celeb-DF*, sendo 200 *fake* e 200 sem manipulação. Além de ocorrer em 16 vídeos de um conjunto de dados customizado.

As validações foram realizadas tanto no modelo temporal quanto no espacial (*frame a frame*).

4.2. Matthews Correlation Coefficient (MCC)

O *Matthews Correlation Coefficient* (MCC) é uma métrica de avaliação de modelos de classificação binária, que posteriormente foi extrapolada para classificação multiclasse. [Jurman, Riccadonna e Furlanello 2012]

Neste trabalho será utilizado o MCC, juntamente com a acurácia para avaliar a eficácia dos modelos na detecção de *deepfakes*.

4.3. Hardware

Para o desenvolvimento do modelo, foram utilizados dois computadores distintos, que serão descritos a seguir:

Notebook Avell:

- **CPU:** Intel Core i5-9300H
- **Memória:** 64 GiB
- **Placa de vídeo:** NVIDIA GeForce GTX 1050 4GB

Mac Mini:

- **CPU:** Apple M1 - 8 Cores (4 de performance e 4 de eficiência)
- **Memória:** 16GB

Além destes hardwares citados, foi utilizado no treinamento e na predição o *Google Colab*, no plano Pro. É disponibilizada diferentes placas de vídeo (GPU), que garantiu que ocorresse o treinamento do modelo e a validação cruzada sem intercorrências.

4.4. Pré-Processamento dos dados

Por conta da restrição computacional, o pré-processamento foi realizado utilizando a biblioteca MTCNN [K. Zhang et al. 2016]; [Kaipeng Zhang et al. 2017] para a identificação e extração das faces dos *frames* do vídeo. No entanto, como o *dataset* do FaceForensics++ tem um alto volume de dados, mesmo tendo se limitado aos vídeos comprimidos (c23), foi necessário restringir a quantidade de *frames* avaliados.

Para cada vídeo processado do *dataset*, estas foram as restrições impostas:

- *skip* de *frames* = 9
- quantidade máxima de *frames* avaliados que contenham um rosto detectado = 30
- limite de leitura total de *frames* por vídeo = 1000

4.5. Experimentos

Para a construção do modelo final que será utilizado para a validação cruzada tanto *in-domain*, quanto *cross-domain*, foram realizados diversos experimentos para o *fine-tuning* do modelo.

A tabela 1 trás os experimentos realizados com as respectivas métricas de desempenho.

Tabela 1. Resumo comparativo de todos os experimentos do pipeline de detecção de deepfakes no FaceForensics++ (FF++).

Experimento / Abordagem	Estratégia Principal	Nível	Acurácia (%)	Recall Real	AUC-ROC
Experimento 1	Baseline (Treino Inicial)	Frame	85,50	0,4500	0,8740
Experimento 2	Treino Restaurado	Frame	84,20	0,5400	0,8720
Experimento 3	Ajuste de Limiar (<i>Threshold</i>)	Frame	78,00	0,8100	0,8720
Experimento 4	Ponderação de Classes (<i>Class Weighting</i>)	Frame	81,00	0,7400	0,8720
Experimento 5 (Original)	Focal Loss + MixUp até Época 5	Frame	80,70	0,7500	0,8710
Experimento 5 (Re-execução)	Validação Padrão Ouro	Frame	83,00	0,7100	0,8800
BiGRU Temporal (Validação)	Agregação Sequencial (30 frames)	Vídeo	88,70	0,9787	0,9854
BiGRU Temporal (Teste)	Avaliação Final em Nível de Vídeo	Vídeo	88,30	0,9886	0,9825

Para garantir que a rede priorize exemplos complexos durante o treinamento e ganhe robustez, conforme proposto por Anjali Sharma, Rani e Arun Sharma (2025), avaliou-se a substituição da função de perda *binary cross-entropy* pela *focal loss*.

Com os resultados obtidos nos experimentos, foram salvos para utilização na predição posterior em *cross-domain* os modelos: Espacial Experimento 5 (*Focal Loss* + *MixUp* até Época 5) e *BiGRU* temporal com *Focal Loss*.

O experimento com *BiGRU* foi executado para tentar avaliar se haveria uma melhora de performance ao avaliar além do quesito espacial, considerar também o temporal. [Abbood et al. 2026]

Como observado na Tabela 1 houve uma melhoria considerável nas métricas de acurácia, *Recall* real e principalmente em *AUC-ROC*.

4.6. Análise do desempenho

Para analisar a eficácia na detecção de *deepfakes* através dos dados disponíveis é necessário avaliar os comportamentos dos modelos e para isso serão utilizadas as seguintes métricas: (i) probabilidade de detecção, (ii) acurácia, (iii) probabilidade de detecção falsa, (iv) probabilidade de alarme falso, (v) taxa de erro, (vi) coeficiente MCC, (vii) F1 score, (viii) especificidade.

5. Resultados e discussões

Com base nos dados da Tabela X podemos avaliar o desempenho dos modelos utilizados na detecção de *deepfakes*.

5.1. Probabilidade de detecção

5.2. Acurácia

5.3. Probabilidade de alarme falso

5.4. Taxa de erro

5.5. Coeficiente MCC

5.6. F1 score

5.7. Especificidade

6. Conclusão

7. Trabalhos Futuros

Referências

- Abbood, Zainab Ali et al. (jun. de 2026). “Enhancing Deepfake Detection with Explainable AI Through Neural-Symbolic RCNN-BiGRU Approach”. Em: *Al-Iraqia Journal for Scientific Engineering Research* 5.2, pp. 30–42. ISSN: 2710-2165. DOI: 10.58564/IJSER.5.2.2026.369. (Acesso em 17/08/2026).
- Corrêa, Luciana (fev. de 2026). *I Panorama da Desinformação no Brasil: padrões, estratégias e impacto • Lupa*. URL: <https://www.agencialupa.org/observatorio/2026/02/05/i-panorama-da-desinformacao-no-brasil-padroes-estrategias-e-impacto/> (acesso em 27/05/2026).
- Dagar, Deepak e Dinesh Kumar Vishwakarma (set. de 2022). “A Literature Review and Perspectives in Deepfakes: Generation, Detection, and Applications”. Em: *International Journal of Multimedia Information Retrieval* 11.3, pp. 219–289. ISSN: 2192-662X. DOI: 10.1007/s13735-022-00241-w. URL: <https://doi.org/10.1007/s13735-022-00241-w> (acesso em 14/07/2026).
- Google (2026). *Veo 3 — Google AI Studio*. URL: <https://aistudio.google.com/models/veo-3> (acesso em 27/05/2026).
- Hameleers, Michael, Toni G. L. A. van der Meer e Tom Dobber (2024). “They Would Never Say Anything Like This! Reasons To Doubt Political Deepfakes”. Em: *European Journal of Communication* 39.1, pp. 56–70. DOI: 10.1177/02673231231184703.
- Hameleers, Michael, Toni G. L. A. van der Meer e Tom Dobber (jul. de 2022). “You Won’t Believe What They Just Said! The Effects of Political Deepfakes Embedded as Vox Populi on Social Media”. Em: *Social Media + Society* 8.3, p. 20563051221116346. ISSN: 2056-3051. DOI: 10.1177/20563051221116346. URL: <https://doi.org/10.1177/20563051221116346> (acesso em 26/05/2026).
- Jurman, Giuseppe, Samantha Riccadonna e Cesare Furlanello (2012). “A Comparison of MCC and CEN Error Measures in Multi-Class Prediction”. Em: *PLOS ONE* 7.8, pp. 1–8. DOI: 10.1371/journal.pone.0041882. URL: <https://doi.org/10.1371/journal.pone.0041882>.
- Kling, AI (2026). *Kling AI: Next-Generation AI Creative Studio*. URL: <https://kling.ai/> (acesso em 27/05/2026).
- Li, Yuezun et al. (mar. de 2020). *Celeb-DF: A Large-scale Challenging Dataset for DeepFake Forensics*. DOI: 10.48550/arXiv.1909.12962. arXiv: 1909.12962 [cs.CR]. URL: <http://arxiv.org/abs/1909.12962> (acesso em 14/05/2026).

- Liu, Qiang, Lin Wang e Mengyu Luo (fev. de 2025). “When Seeing Is Not Believing: Self-Efficacy and Cynicism in the Era of Intelligent Media”. Em: *Humanities and Social Sciences Communications* 12.1, p. 274. ISSN: 2662-9992. DOI: 10.1057/s41599-025-04594-5. URL: <https://www.nature.com/articles/s41599-025-04594-5> (acesso em 26/05/2026).
- Mahr, Dana (mai. de 2026). “Sexualized Deepfakes as a Socio-Technical Continuation of Gendered Power”. Em: *AI & SOCIETY*. ISSN: 1435-5655. DOI: 10.1007/s00146-026-03080-z. URL: <https://doi.org/10.1007/s00146-026-03080-z> (acesso em 14/05/2026).
- Rana, Md Shohel et al. (2022). “Deepfake Detection: A Systematic Literature Review”. Em: *IEEE Access* 10, pp. 25494–25513. ISSN: 2169-3536. DOI: 10.1109/ACCESS.2022.3154404. URL: <https://ieeexplore.ieee.org/document/9721302> (acesso em 14/07/2026).
- Rössler, Andreas et al. (ago. de 2019). *FaceForensics++: Learning to Detect Manipulated Facial Images*. DOI: 10.48550/arXiv.1901.08971. arXiv: 1901.08971 [cs.CV]. URL: <http://arxiv.org/abs/1901.08971> (acesso em 14/05/2026).
- Runway (2026). *Runway — Building AI to Simulate the World*. URL: <https://runwayml.com/> (acesso em 27/05/2026).
- SaferNet, Brasil (2026). *Mapeamento da SaferNet identifica deepfakes sexuais em escolas em 10 dos 27 estados brasileiros*. URL: <https://new.safernet.org.br/content/mapeamento-da-safernet-identifica-deepfakes-sexuais-em-escolas-em-10-dos-27-estados> (acesso em 27/05/2026).
- Security, Hero (2023). *2023 State Of Deepfakes: Realities, Threats, And Impact — Security Hero*. URL: <https://www.securityhero.io/state-of-deepfakes/> (acesso em 26/05/2026).
- Selvaraju, Ramprasaath R. et al. (2016). “Grad-CAM: Why did you say that? Visual Explanations from Deep Networks via Gradient-based Localization”. Em: *CoRR* abs/1610.02391. arXiv: 1610.02391. URL: <http://arxiv.org/abs/1610.02391>.
- Sharma, Anjali, Ritu Rani e Arun Sharma (abr. de 2025). “Exploring the Role of Loss Functions in Deepfake Detection”. Em: *2025 International Conference on Data Science and Business Systems (ICDSBS)*, pp. 1–6. DOI: 10.1109/ICDSBS63635.2025.11031727. (Acesso em 17/08/2026).
- Sharma, Vishal Kumar, Rakesh Garg e Quentin Caudron (jun. de 2025). “A Systematic Literature Review on Deepfake Detection Techniques”. Em: *Multimedia Tools and Applications* 84.20, pp. 22187–22229. ISSN: 1573-7721. DOI: 10.1007/s11042-024-19906-1. URL: <https://doi.org/10.1007/s11042-024-19906-1> (acesso em 14/07/2026).
- T, Lavanya, C. Pandeeswaran e L. Steffina Morin (2025). “Combating Deepfakes: A Transformer - Obtained and Explainable Frameworks for Robust Video Integrity Verification”. Em: *2025 International Conference on Sustainable Communication Networks and Application (ICSCN)*, pp. 1610–1617. DOI: 10.1109/ICSCN67106.2025.11308255.
- Tschannen, Michael et al. (2025). *SigLIP 2: Multilingual Vision-Language Encoders with Improved Semantic Understanding, Localization, and Dense Features*. arXiv: 2502.14786 [cs.CV]. URL: <https://arxiv.org/abs/2502.14786>.

- Zhang, K. et al. (out. de 2016). “Joint Face Detection and Alignment Using Multitask Cascaded Convolutional Networks”. Em: *IEEE Signal Processing Letters* 23.10, pp. 1499–1503. ISSN: 1070-9908. DOI: 10.1109/LSP.2016.2603342.
- Zhang, Kaipeng et al. (2017). “Detecting faces using inside cascaded contextual cnn”. Em: *Proceedings of the IEEE International Conference on Computer Vision*, pp. 3171–3179.